

 COLE NATIONALE SUP RIEURE POLYTECHNIQUE DE DOUALA
D partement GIT - Fili re SDIA

BIBLE DU PROJET AD2 - #07

Pr vision de la Consommation  lectrique au Cameroun

Guide de R f rence Complet · Pipeline EDA - ARIMA

Cours : Analyse de Donn es 2 (AD2)
Enseignant : M. FOTSO Valdez
Groupe de 5  tudiants · Ann e 2025/2026
ENSPD Douala

0. Vue d'ensemble du Projet

Ce document constitue la BIBLE officielle du Groupe #07. Il r capitule,  tape par  tape, tout ce que notre  quipe doit produire, comment le coder, comment le r diger et comment le pr senter. Gardons-le ouvert pendant toute la dur e du projet.

0.1 Fiche d'identit  du projet

Crit�re	D�tail
Num�ro du projet	#07
Domaine	�nergie & D�veloppement Durable
M�thode factorielle	ACP — Analyse en Composantes Principales (non supervis�)
ARIMA	OBLIGATOIRE (pas optionnel)
Difficult�	Avanc�
Groupe	5 �tudiants
Note totale	20 points + 2 bonus
Enseignant	M. FOTSO Valdez

0.2 Les 4 questions auxquelles vous devez r pondre

QUESTIONS CL S   TRAITER (bar me direct)

- Q1 - Quels sont les patterns horaires, journaliers et saisonniers de consommation ?
- Q2 - Comment la temp rature influence-t-elle la consommation ?
- Q3 - Peut-on pr voir la consommation des 48 prochaines heures (et des 7 jours) ?
- Q4 - Quelles p riodes pr sentent les risques de surcharge les plus  lev s ?

0.3 Pipeline global (EDA → ARIMA)

�tape	Nom	M�thode	Points
1	Exploration (EDA)	pandas, seaborn, matplotlib	4 pts (mutualis� avec pr�pro)
2	Pr�traitement	StandardScaler, interpolation, IQR	� idem
3	D�composition temporelle	seasonal_decompose, ADF	Obligatoire #07
4	ACP	PCA sklearn (95 % variance)	3 pts
5	Clustering K-Means	KMeans, coude, silhouette	4 pts (mutualis� DBSCAN)
6	Clustering DBSCAN	DBSCAN (eps, min_samples)	� idem
7	Classification	DecisionTree + RandomForest	4 pts
8	SARIMA	SARIMAX statsmodels	Inclus dans les crit�res ci-dessus
BONUS	Dashboard	Site vitrine statique	+2 pts

1. Organisation de l'Équipe & Rôles

1.1 Tableau des rôles

Rôle	Prénom à remplir	Responsabilités principales	Sections rapport
Chef de projet	Aat Ndongo	Planification, GitHub (branches/PR), réunions quotidiennes 9h, communication enseignant, intégration finale	Introduction, Conclusion
Resp. Code	Ivana Djeutchou	Structure dépôt, notebook final, random_state=42, revue de code, requirements.txt	Annexes code
Resp. Rapport	Evengue Philomene	Rédaction sections 2-6, qualité figures, normes (police, pages, reliure)	EDA, Prétraitement, ACP
Resp. Présentation	Halimatou Sadiya	Création slides PowerPoint, coordination oral, minutage, design	Clustering, Classification
Resp. Validation	Etia Patrick	Tests modèles, métriques, hypothèses (stationnarité), gestion conflits Git	Séries temporelles

1.2 Planning 10 jours

Jour	Tâches clés	Responsable(s)
J1	Installation Python 3.10, pandas, sklearn, statsmodels. Création GitHub, requirements.txt. Récupération dataset.	Tous + Chef
	EDA complète : stats, visualisations, corrélations, saisonnalité. Début rédaction section EDA.	Resp. Rapport + Code
J2	Prétraitement : NA, variables temporelles, normalisation, outliers IQR.	Resp. Code + Validation
	ACP : scree plot, cercle corrélations, interprétation axes. Intégration rapport.	Resp. Code + Rapport
J3	Clustering: K-Means (coude, silhouette) + DBSCAN. Visualisation profils.	Resp. Code + Validation
	Classification : Arbre + Random Forest, validation croisée, importances variables.	Resp. Code + Validation
J4	Séries temporelles : ADF, ACF/PACF, SARIMA, prévision 7 jours, métriques.	Resp. Code + Validation
	Finalisation notebook, vérif random_state, rédaction conclusion/annexes.	Tous
J5	Création PowerPoint, répétition soutenance chronométrée.	Resp. Présentation + Tous
	Impression rapport (recto-verso, reliure), envoi notebook, push GitHub final.	Chef + Tous

2. Donn es - Sources & Structure

2.1 Sources recommand es

Source	URL / Lien	Usage
Kaggle - Hourly Energy Consumption (PJM/AEP)	kaggle.com/datasets/robikscube/hourly-energy-consumption	Donn�es horaires MW - rebaptis�es « ENEO synth�tiques »
Open Power System Data	open-power-system-data.org	Profils de charge europ�ens (inspiration)
World Bank - Energy	data.worldbank.org/topic/energy-and-mining	Indicateurs macro Cameroun (PIB, pop)
IEA - Africa Energy Outlook	iea.org/reports/africa-energy-outlook-2022	Contexte africain, s�ries de r�f�rence

NOTE P DAGOGIQUE ACCEPT E PAR L'ENSEIGNANT

Faute de donn es publiques camerounaises d taill es, nous pouvons utiliser le jeu AEP (American Electric Power) et le rebaptiser « Donn es ENEO synth tiques ».

Justification   inclure dans le rapport : climatologie tropicale similaire (double pointe journali re) + urbanisation croissante = profil de charge comparable.

2.2 Variables du dataset

Variable	Type	Description	Source
datetime	Index DatetimeIndex	Horodatage horaire (pas = 1h)	Raw dataset
consumption	float (MW)	Consommation �lectrique en m�gawatts	Raw dataset
temperature	float (�C)	Temp�rature ext�rieure	M�t�o (� merger)
humidity	float (%)	Humidit� relative	M�t�o (� merger)
hour	int 0-23	Heure extraite du datetime	Feature engineering
day_of_week	int 0-6	Jour de la semaine (0=Lundi)	Feature engineering
month	int 1-12	Mois de l'ann�e	Feature engineering
is_weekend	int 0/1	1 si samedi ou dimanche	Feature engineering

2.3 G n ration synth tique (si aucune donn e disponible)

Si vous ne pouvez pas t l charger de dataset, cr ez une s rie r aliste avec numpy :

```
import numpy as np, pandas as pd
np.random.seed(42)
n = 8760 # 1 an horaire
t = np.arange(n)
tendance = 0.01 * t
saison_annuelle = 50 * np.sin(2*np.pi*t/8760) # saison s che/pluies
```

```
saizon_jour = 100 * np.sin(2*np.pi*(t % 24)/24 - np.pi/2) # double pointe  
bruit = np.random.normal(0, 20, n)  
conso = 500 + tendance + saizon_annuelle + saizon_jour + bruit  
idx = pd.date_range('2023-01-01', periods=n, freq='h')  
df = pd.DataFrame({'consumption': conso}, index=idx)
```

→ Mentionnez explicitement dans le rapport que les donn es sont synth tiques et justifiez la mod lisation choisie.

3.  tape 1 - EDA (Exploratory Data Analysis)

BAR ME : 4 points (mutualis s avec pr traitement)

Visualisations pertinentes et comment es, gestion NA, cr ation variables temporelles, justifications.

3.1 Statistiques descriptives

Ce qu'on attend dans le rapport : tableaux min, max, moyenne, m diane,  cart-type, valeurs manquantes.

```
df.info()
df.describe()
df.isnull().sum()
```

3.2 Visualisations temporelles obligatoires

Visualisation	Code cl�	Interpr�tation attendue
Courbe sur 1 mois	df['2023-01'].plot(figsize=(14,4))	Tendance + double pointe visible
Courbe sur 1 semaine	df['2023-01-01':'2023-01-07'].plot()	Profil semaine/week-end distinct
Courbe sur 1 jour	df['2023-01-03'].plot()	Creux 2h-5h, pointe 7h + 20h
Boxplot par heure	df.groupby('hour')['consumption'].plot.box()	Heures de pointe et creuses
Heatmap corr�lations	sns.heatmap(df.corr(), annot=True)	Liens conso � temp�rature, heure
Courbe rolling mean	df.rolling(24*7).mean().plot()	Tendance liss�e sur 7 jours

3.3 Code EDA complet

```
import pandas as pd, matplotlib.pyplot as plt, seaborn as sns

# Feature engineering temporel
df['hour'] = df.index.hour
df['day_of_week'] = df.index.dayofweek
df['month'] = df.index.month
df['is_weekend'] = (df['day_of_week'] >= 5).astype(int)

# Boxplot par heure - heures de pointe
fig, ax = plt.subplots(figsize=(14, 5))
df.boxplot(column='consumption', by='hour', ax=ax)
ax.set_title('Distribution horaire de la consommation')
plt.suptitle('')
plt.tight_layout()
plt.savefig('eda_boxplot_horaire.png', dpi=150)

# Heatmap heure x jour
```

```
pivot = df.pivot_table(values='consumption', index='hour', columns='day_of_week',  
aggfunc='mean')  
sns.heatmap(pivot, cmap='YlOrRd', annot=True, fmt='.0f')  
plt.title('Consommation moyenne heure x jour de semaine')  
plt.savefig('eda_heatmap_jour.png', dpi=150)
```

4.  tape 2 - Pr traitement

4.1 Gestion des valeurs manquantes

R GLE #07 : interpolation lin aire (ne jamais supprimer des lignes dans une s rie temporelle).

```
df['consumption'] = df['consumption'].interpolate(method='linear')
# V rification
assert df['consumption'].isnull().sum() == 0, 'Valeurs manquantes restantes !'
```

4.2 D tection d'outliers (IQR)

Attention : conservez les pointes de consommation, ce sont des  v nements d'int r t m tier (pas des erreurs).

```
Q1 = df['consumption'].quantile(0.25)
Q3 = df['consumption'].quantile(0.75)
IQR = Q3 - Q1
lower, upper = Q1 - 3*IQR, Q3 + 3*IQR # seuil plus large que 1.5
outliers = df[(df['consumption'] < lower) | (df['consumption'] > upper)]
print(f'{len(outliers)} outliers d tect s (probables d lestages ou pics)')
```

4.3 Normalisation / Standardisation

Technique	Quand l'utiliser	Code
StandardScaler	ACP, clustering, classification	from sklearn.preprocessing import StandardScaler X_scaled = StandardScaler().fit_transform(X)
MinMaxScaler	Optionnel pour ARIMA	from sklearn.preprocessing import MinMaxScaler X_norm = MinMaxScaler().fit_transform(X)

4.4 Feature engineering complet

```
df['hour'] = df.index.hour
df['day_of_week'] = df.index.dayofweek
df['month'] = df.index.month
df['is_weekend'] = (df['day_of_week'] >= 5).astype(int)
df['quarter'] = df.index.quarter
# Lags (bonus)
df['lag_24h'] = df['consumption'].shift(24) # m me heure hier
df['lag_168h'] = df['consumption'].shift(168) # m me heure semaine pass e
df['roll_24h'] = df['consumption'].rolling(24).mean() # moyenne mobile 24h
```

5.  tape 3 - D composition & Stationnarit  (Obligatoire #07)

LIVRABLE SP CIFIQUE #07

D composition saisonni re multi- chelle (tendance + saisonnalit  journali re + annuelle).
Test de stationnarit  ADF avant mod lisation SARIMA.

5.1 D composition saisonni re

```
from statsmodels.tsa.seasonal import seasonal_decompose

# D composition sur donn es journali res (agr g es)
daily = df['consumption'].resample('D').mean()
decomp = seasonal_decompose(daily, model='additive', period=7)
fig = decomp.plot()
fig.set_size_inches(14, 10)
plt.suptitle('D composition saisonni re - Consommation ENEO (quotidien)', y=1.02)
plt.tight_layout()
plt.savefig('decomposition_saisonniere.png', dpi=150)

# D composition horaire (saisonnalit  journali re)
decomp_h = seasonal_decompose(df['consumption'], model='additive', period=24)
```

5.2 Test de stationnarit  ADF

La s rie doit  tre stationnaire avant d'ajuster ARIMA. $p\text{-value} < 0.05 \rightarrow$ stationnaire.

```
from statsmodels.tsa.stattools import adfuller

def test_adf(series, name='s rie'):
    result = adfuller(series.dropna())
    print(f'--- Test ADF : {name} ---')
    print(f' Statistique ADF : {result[0]:.4f}')
    print(f' p-value : {result[1]:.4f}')
    print(f' Stationnaire : {"OUI" if result[1] < 0.05 else "NON - diff rencier"}')
    return result[1] < 0.05

stationnaire = test_adf(daily, 'Consommation journali re')
if not stationnaire:
    daily_diff = daily.diff().dropna()
    test_adf(daily_diff, 'Consommation diff renci e (d=1)')
```

5.3 ACF / PACF - Identification des ordres p, d, q

```
from statsmodels.graphics.tsaplots import plot_acf, plot_pacf

fig, (ax1, ax2) = plt.subplots(2, 1, figsize=(14, 8))
plot_acf(daily_diff, lags=40, ax=ax1, title='ACF - Autocorr lation (  ordre q)')
plot_pacf(daily_diff, lags=40, ax=ax2, title='PACF - Autocorr lation partielle (  ordre p)')
plt.tight_layout()
plt.savefig('acf_pacf.png', dpi=150)
```

→ q = dernier lag significatif dans l'ACF. p = dernier lag significatif dans le PACF.

6.  tape 4 - ACP (Analyse en Composantes Principales)

BAR ME : 3 points

Scree plot, plan factoriel, cercle des corr lations, variance expliqu e, interpr tation des axes.

6.1 Matrice d'entr e pour l'ACP

L'ACP s'applique sur les variables m t o et temporelles (pas directement sur la s rie de consommation).

```
features_acp = ['temperature', 'humidity', 'hour', 'day_of_week', 'month',
                'is_weekend']
X = df[features_acp].dropna()
from sklearn.preprocessing import StandardScaler
X_scaled = StandardScaler().fit_transform(X)
```

6.2 Code ACP complet

```
from sklearn.decomposition import PCA
import numpy as np, matplotlib.pyplot as plt

# ACP avec 95% de variance expliqu e
pca = PCA(n_components=0.95, random_state=42)
components = pca.fit_transform(X_scaled)
print(f'Nombre de composantes retenues : {pca.n_components_}')
print(f'Variance expliqu e cumul e      : {pca.explained_variance_ratio_.cumsum()}')

# - Scree Plot -
plt.figure(figsize=(8, 5))
plt.bar(range(1, pca.n_components_+1), pca.explained_variance_ratio_*100,
        color='steelblue')
plt.plot(range(1, pca.n_components_+1),
         pca.explained_variance_ratio_.cumsum()*100, 'r-o')
plt.xlabel('Composante principale')
plt.ylabel('Variance expliqu e (%)')
plt.title('Scree Plot - ACP Consommation ENEO')
plt.axhline(y=95, color='green', linestyle='--', label='Seuil 95%')
plt.legend()
plt.savefig('acp_scree.png', dpi=150)

# - Cercle des corr lations (axes 1 et 2) -
fig, ax = plt.subplots(figsize=(7, 7))
circle = plt.Circle((0,0), 1, fill=False, color='gray', linestyle='--')
ax.add_patch(circle)
for i, feat in enumerate(features_acp):
    ax.annotate(feat, xy=(pca.components_[0][i], pca.components_[1][i]),
               fontsize=11)
    ax.arrow(0, 0, pca.components_[0][i], pca.components_[1][i],
            head_width=0.03, color='navy')
ax.set_xlim(-1.2, 1.2); ax.set_ylim(-1.2, 1.2)
ax.set_xlabel('PC1'); ax.set_ylabel('PC2')
ax.set_title('Cercle des corr lations - ACP')
plt.savefig('acp_cercle.png', dpi=150)
```

6.3 Interpr tation attendue dans le rapport

Axe	Interpr�tation probable	Variables dominantes
PC1	Opposition jour / nuit	hour (+), is_weekend (-)
PC2	Opposition saison s�che / pluies	month (+), humidity (-)
PC3	Effet thermique (si retenu)	temperature (+), humidity (-)

Note : remplacez les variables m t o par les 2–3 premi res composantes pour le clustering.

7.  tape 5 - Clustering (K-Means + DBSCAN)

BAR ME : 4 points

K-Means (m thode du coude + silhouette) ET DBSCAN, comparaison, profilage m tier des clusters.

7.1 K-Means - D termination du k optimal

```
from sklearn.cluster import KMeans
from sklearn.metrics import silhouette_score
import matplotlib.pyplot as plt

inertias, silhouettes = [], []
K_range = range(2, 9)
for k in K_range:
    km = KMeans(n_clusters=k, random_state=42, n_init=10)
    labels = km.fit_predict(X_scaled)
    inertias.append(km.inertia_)
    silhouettes.append(silhouette_score(X_scaled, labels))

fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(14, 5))
ax1.plot(K_range, inertias, 'bo-'); ax1.set_title('M thode du coude (inertie)')
ax2.plot(K_range, silhouettes, 'gs-'); ax2.set_title('Score silhouette')
plt.savefig('kmeans_choix_k.png', dpi=150)
```

7.2 K-Means - Profilage des clusters

```
k_optimal = 4 #   ajuster selon le coude/silhouette
km_final = KMeans(n_clusters=k_optimal, random_state=42, n_init=10)
df['cluster_kmeans'] = km_final.fit_predict(X_scaled)

# Courbe de consommation moyenne par cluster
fig, axes = plt.subplots(1, k_optimal, figsize=(16, 4))
for c in range(k_optimal):
    subset = df[df['cluster_kmeans'] == c]
    subset.groupby('hour')['consumption'].mean().plot(ax=axes[c])
    axes[c].set_title(f'Cluster {c} - n={len(subset)}')
plt.suptitle('Profil horaire de consommation par cluster')
plt.savefig('kmeans_profils.png', dpi=150)
```

7.3 DBSCAN - D tection des journ es atypiques

DBSCAN identifie les points aberrants sans forcer tous les points dans un cluster. Les labels=-1 sont les anomalies (d lestages, pointes extr mes).

```
from sklearn.cluster import DBSCAN

# Tester plusieurs eps
for eps_val in [0.3, 0.5, 0.8, 1.0]:
    db = DBSCAN(eps=eps_val, min_samples=5)
    labels_db = db.fit_predict(X_scaled)
    n_noise = (labels_db == -1).sum()
```

```
print(f'eps={eps_val} → {len(set(labels_db))-1} clusters, {n_noise} anomalies')

# Mod le final
db_final = DBSCAN(eps=0.5, min_samples=5)
df['cluster_dbscan'] = db_final.fit_predict(X_scaled)
anomalies = df[df['cluster_dbscan'] == -1]
print(f'Anomalies d tect es : {len(anomalies)} heures ({len(anomalies)/len(df)*100:.1f}%)')
```

7.4 Comparaison K-Means vs DBSCAN (  mettre dans le rapport)

Crit�re	K-Means	DBSCAN
Nombre de clusters	Fix� a priori (k=4)	D�couvert automatiquement
Gestion des outliers	Force tous les points dans un cluster	Isole les anomalies (label=-1)
Forme des clusters	Clusters sph�riques seulement	Formes arbitraires
Utilisation #07	Profilage des journ�es type	D�tection d�lestages/surcharges
Param�tre cl�	k (m�thode du coude)	eps + min_samples (grille de recherche)

8.  tape 6 - Classification Supervis e

BAR ME : 4 points

2 mod les (Arbre + Random Forest), validation crois e 5-fold, m triques F1/recall, importance des variables, interpr tation de la matrice de confusion.

8.1 D finition de la variable cible

Seuil recommand  : 90e percentile de la consommation = jour « critique » (  risque de surcharge).

```
seuil = df['consumption'].quantile(0.90)
df['critique'] = (df['consumption'] >= seuil).astype(int)
print(f'Seuil critique : {seuil:.1f} MW')
print(f'Distribution : {df["critique"].value_counts()})
```

8.2 Arbre de D cision

```
from sklearn.tree import DecisionTreeClassifier, export_text
from sklearn.model_selection import train_test_split, cross_val_score
from sklearn.metrics import classification_report, confusion_matrix

features = ['temperature', 'humidity', 'hour', 'day_of_week', 'month',
            'is_weekend']
X_cls = df[features].dropna()
y_cls = df.loc[X_cls.index, 'critique']

X_train, X_test, y_train, y_test = train_test_split(
    X_cls, y_cls, test_size=0.2, random_state=42, stratify=y_cls)

dt = DecisionTreeClassifier(max_depth=5, random_state=42)
dt.fit(X_train, y_train)
y_pred_dt = dt.predict(X_test)
print('=== ARBRE DE D CISION ===')
print(classification_report(y_test, y_pred_dt))
print(confusion_matrix(y_test, y_pred_dt))
```

8.3 Random Forest + importance des variables

```
from sklearn.ensemble import RandomForestClassifier
import pandas as pd, matplotlib.pyplot as plt

rf = RandomForestClassifier(n_estimators=200, random_state=42, n_jobs=-1)
rf.fit(X_train, y_train)
y_pred_rf = rf.predict(X_test)

# Validation crois e 5-fold
scores = cross_val_score(rf, X_cls, y_cls, cv=5, scoring='f1')
print(f'F1 moyen (CV 5-fold) : {scores.mean():.3f} ± {scores.std():.3f}')

# Importance des variables
importances = pd.Series(rf.feature_importances_,
                        index=features).sort_values(ascending=False)
```

```
importances.plot.bar(figsize=(10, 5), color='steelblue')
plt.title('Importance des variables - Random Forest')
plt.savefig('rf_importance.png', dpi=150)
```

8.4 Tableau comparatif   ins rer dans le rapport

M�trique	Arbre de D�cision	Random Forest	Meilleur mod�le
Accuracy	� mesurer	� mesurer	RF g�n�ralement
Pr�cision (critique)	� mesurer	� mesurer	RF
Rappel (critique)	� mesurer	� mesurer	RF
F1-score (critique)	� mesurer	� mesurer	RF
CV 5-fold F1	� mesurer	� mesurer	RF
Interpr�tabilit�	Haute (arbre visible)	Moyenne (bo�te noire)	Arbre

9.  tape 7 - S ries Temporelles SARIMA (OBLIGATOIRE)

LIVRABLES OBLIGATOIRES #07

- Pr vision 7 jours avec intervalles de confiance   95%
- D composition saisonni re multi- chelle
- Rapport de risques de surcharge

9.1 Agr gation en donn es journali res

```
daily = df['consumption'].resample('D').mean()
print(f'S rie journali re : {len(daily)} jours')

# Split train/test 80/20
n = len(daily)
split = int(n * 0.8)
train, test = daily[:split], daily[split:]
print(f'Train : {len(train)} jours | Test : {len(test)} jours')
```

9.2 Identification des ordres avec auto_arima (recommand )

```
# Installation : pip install pmdarima
from pmdarima import auto_arima

model_auto = auto_arima(train,
                        seasonal=True, m=7, # saisonnalit  hebdomadaire
                        d=None,             # auto-diff renciation
                        trace=True,         # affiche les mod les test s
                        error_action='ignore',
                        suppress_warnings=True)

print(model_auto.summary())
p, d, q = model_auto.order
P, D, Q, s = model_auto.seasonal_order
```

9.3 Ajustement SARIMA

```
from statsmodels.tsa.statespace.sarimax import SARIMAX
import warnings
warnings.filterwarnings('ignore')

# Param tres identifi s par auto_arima (exemple)
p, d, q = 1, 1, 1
P, D, Q, s = 1, 0, 1, 7

model = SARIMAX(train, order=(p, d, q),
                seasonal_order=(P, D, Q, s),
                enforce_stationarity=False,
                enforce_invertibility=False)

results = model.fit(dispatch=False)
print(results.summary())
```

9.4 Pr vision 7 jours avec intervalles de confiance 95%

```
# Pr vision sur la p riode test
pred_test = results.get_prediction(start=test.index[0], end=test.index[-1])
pred_ci = pred_test.conf_int(alpha=0.05) # 95%

# Pr vision future 7 jours
forecast = results.get_forecast(steps=7)
pred_mean = forecast.predicted_mean
conf_int = forecast.conf_int(alpha=0.05)

# - Graphique complet -
fig, ax = plt.subplots(figsize=(16, 6))
train[-60:].plot(ax=ax, label='Train (60 derniers jours)', color='steelblue')
test.plot(ax=ax, label='R el (test)', color='green')
pred_test.predicted_mean.plot(ax=ax, label='Pr dit (test)', color='orange',
                             linestyle='--')
pred_mean.plot(ax=ax, label='Pr vision 7 jours', color='red', linestyle='--')
ax.fill_between(conf_int.index,
                conf_int.iloc[:,0], conf_int.iloc[:,1],
                color='red', alpha=0.15, label='IC 95%')
ax.set_title('Pr vision SARIMA - Consommation ENEO - 7 jours')
ax.set_ylabel('Consommation (MW)')
ax.legend(loc='upper left')
plt.tight_layout()
plt.savefig('sarima_prevision_7j.png', dpi=150)
```

9.5 M triques d valuation

```
from sklearn.metrics import mean_absolute_error, mean_squared_error
import numpy as np

y_true = test.values
y_pred = pred_test.predicted_mean.values[:len(y_true)]

mae = mean_absolute_error(y_true, y_pred)
rmse = np.sqrt(mean_squared_error(y_true, y_pred))
mape = np.mean(np.abs((y_true - y_pred) / y_true)) * 100

print(f'MAE : {mae:.2f} MW')
print(f'RMSE : {rmse:.2f} MW')
print(f'MAPE : {mape:.2f} %')
```

9.6 Rapport de risques de surcharge

D finissez un seuil de surcharge (ex. 95e percentile de la consommation) et identifiez les p riodes   risque dans la pr vision.

```
seuil_surcharge = daily.quantile(0.95)
risques = pred_mean[pred_mean > seuil_surcharge]
print(f'P riodes   risque dans les 7 prochains jours :')
print(risques)
```

10. Livrables & Structure du Rapport

10.1 Tableau des livrables

Livrable	Format	Sp�cifications	Responsable
Rapport PDF	Imprim� reli�	20 pages recto-verso	Resp. Rapport + Tous
PowerPoint	Fichier .pptx	15 slides, 15 min pr�sentation + 5 min Q&A, tous les membres parlent	Resp. Pr�sentation + Tous
Notebook Jupyter	Fichier .ipynb	Un seul fichier, cellules ex�cut�es dans l'ordre, random_state=42, envoy� par email	Resp. Code + Tous
Code Python	GitHub priv�	Scripts structur�s, QR code dans le rapport	Resp. Code

10.2 Structure obligatoire du rapport PDF

Section	Contenu attendu	Pages estim�es
Page de garde	Titre, noms, ENSPD, ann�e acad�mique, photo groupe optionnel	1
Table des mati�res	Num�rot�e avec num�ros de pages	1
1. Introduction	Contexte ENEO/SONATREL, probl�matique, objectifs, plan du rapport	1
2. EDA	Dataset (origine, taille, p�riode), stats descriptives, visualisations comment�es	2–4
3. Pr�traitement	Gestion NA (interpolation), features engineering, normalisation — chaque choix justifi�	2–3
4. ACP	Scree plot comment�, cercle des corr�lations interpr�t�, variance expliqu�e, axes nomm�s	2–3
5. Clustering	K-Means (coude, silhouette, k choisi), DBSCAN (eps, min_samples), comparaison tableau	3–4
6. Classification	2 mod�les, m�triques, matrice de confusion, importance variables, comparatif	2–3
7. S�ries temporelles	D�composition, ADF, ACF/PACF, SARIMA ajust�, pr�vision 7j + IC, m�triques, surcharges	2–4
8. Conclusion	R�ponses aux 4 questions, limites, recommandations ENEO	1
Bibliographie	Datasets, librairies Python, articles de r�f�rence	1
Annexes	Code Python complet OU QR code GitHub, tableaux compl�mentaires	1–2

10.3 Livrables spécifiques #07 (notation directe)

LIVRABLES UNIQUES AU PROJET #07 — OBLIGATOIRES

- Graphique de décomposition saisonnière multi-échelle (journalier + annuel) commenté
- Préviation de consommation sur 7 jours avec intervalles de confiance 95%
- Rapport sur les périodes de risque de surcharge avec recommandations ENEO
(ex : renforcer la production entre 18h-22h en saison sèche, prévoir délestage tournant...)

11. Guide Git & Workflow de Collaboration

11.1 Structure du d p t

```

projet07_consommation/
├─ README.md
├─ requirements.txt
├─ projet07_ENEO_complet.ipynb
├─ data/
└─ images/

```

11.2 Branches par membre

Membre	Branche	R�pertoire principal
Chef de projet	feature/integration	rapport/, slides/, README.md
Resp. Code	feature/notebook	notebooks/, scripts/
Resp. Rapport	feature/rapport	rapport/ (Word ou LaTeX)
Resp. Pr�sentation	feature/presentation	presentation/
Resp. Validation	feature/validation	tests/, validation/

11.3 Workflow quotidien

```

# Chaque matin (9h00 – point de 10 min)
git checkout main
git pull origin main
git checkout feature/ma-branche
git merge main # r cup rer les derni res modifs

# Travailler, puis committer
git add .
git commit -m "feat: ajout d composition saisonni re journali re"
git push -u origin feature/ma-branche

# Cr er une Pull Request sur GitHub (vers main)
# → Revue par le Chef de projet → Merge

```

11.4 .gitignore essentiel

```

# Environnements
venv/
__pycache__/
.ipynb_checkpoints/

# Donn es (jamais committer)
data/*.csv
data/*.xlsx

# OS

```

```
.DS_Store  
Thumbs.db
```

11.5 requirements.txt

```
pandas>=2.0.0  
numpy>=1.24.0  
matplotlib>=3.7.0  
seaborn>=0.12.0  
scikit-learn>=1.3.0  
statsmodels>=0.14.0  
pmdarima>=2.0.0  
jupyter>=1.0.0  
plotly>=5.0.0
```

12. Guide de Soutenance Orale

12.1 R partition des r les   l'oral (15 min)

Membre	Partie	Dur�e	Slides
Aat Ndongo (Chef)	Introduction + Contexte ENEO	2 min	Slides 1–3
Evengue (Rapport)	EDA + Pr�traitement	3 min	Slides 4–8
Ivana (Code)	ACP + Clustering	3 min	Slides 9–13
Halimatou (Pr�sentation)	Classification	3 min	Slides 14–18
Patrick (Validation)	SARIMA + Pr�vision + Conclusion	4 min	Slides 19–25

12.2 Structure des slides PowerPoint

Slide	Contenu
1	TITRE : Projet #07 - Pr�vision Consommation ENEO + Noms + ENSPD
2	CONTEXTE : Probl�me des d�lestages, ENEO/SONATREL, les 4 questions cl�s
3	DATASET : Source, taille, p�riode, variables principales
4-5	EDA : Courbes multi-�chelle + boxplot horaire + heatmap heure�jour
6	PR�TRAITEMENT : Choix justifi�s (interpolation NA, features cr��es)
7-8	ACP : Scree plot + cercle des corr�lations comment�
9-11	CLUSTERING : M�thode du coude + profils K-Means + anomalies DBSCAN
12-14	CLASSIFICATION : 2 mod�les, tableau m�triques, importance variables
15-17	SARIMA : D�composition + ACF/PACF + pr�vision 7 jours avec IC 95%
18	RISQUES DE SURCHARGE : P�riodes critiques identifi�es
19-20	CONCLUSION : R�ponses aux 4 questions + Recommandations ENEO

12.3 Questions types   pr parer

QUESTIONS FR QUENTES DU PROFESSEUR — PR PAREZ VOS R PONSES

Q: Pourquoi avoir choisi $k=4$ pour K-Means ?

→ Parce que la m thode du coude montre un coude marqu    $k=4$ et que le score silhouette est maximal pour cette valeur. Cela correspond aux 4 profils : journ e critique, mod r e, basse, et week-end.

Q: Qu'est-ce qu'un mod le SARIMA et pourquoi l'utiliser ici ?

→ SARIMA = AutoRegressive Integrated Moving Average Saisonnier. Il capte la tendance, l'autocorr lation et la saisonnalit  p riodique de la s rie. Id al pour la consommation  lectrique qui a une double saisonnalit  (journali re + hebdomadaire).

Q: Que feriez-vous diff remment avec plus de donn es ?

→ Prophet (Meta) ou LSTM pour mieux capturer plusieurs saisons. Plus de variables exog nes

(donn es m t o locales Douala, jours f ri s camerounais, PIB r gional).

Q: Pourquoi interpoler et non supprimer les valeurs manquantes ?

→ Dans une s rie temporelle, supprimer des lignes cr e des trous qui faussent la saisonnalit . L'interpolation lin aire est coh rente avec la continuit  temporelle.

13. Bar me d' valuation D taill 

Crit�re	Sous-crit�res not�s	Points
EDA + Pr�traitement	Visualisations pertinentes (multi-�chelle), stats descriptives, gestion NA (interpolation), creation variables temporelles, d�tection outliers IQR justifi�e	4
ACP	Scree plot avec seuil 95%, cercle des corr�lations lisible et comment�, nombre de composantes justifi�, axes nomm�s (jour/nuit, saison s�che/pluies)	3
Clustering	K-Means : coude + silhouette + profilage m�tier des clusters. DBSCAN : eps/min_samples choisis + anomalies interpr�t�es. Comparaison des deux m�thodes.	4
Classification	2 mod�les (Arbre + RF), validation crois�e 5-fold, F1/recall/pr�cision, matrice de confusion comment�e, importance des variables Random Forest	4
Rapport + Pr�sentation	Structure obligatoire respect�e, figures comment�es, pas de blocs de code bruts, qualit� r�dactionnelle, tous les membres parlent, slides < 8 lignes	3
ARIMA (obligatoire)	D�composition multi-�chelle, ADF + diff�renciation si n�cessaire, ACF/PACF, SARIMA ajust�, pr�vision 7j + IC95%, MAE/RMSE/MAPE, rapport surcharges	Inclus ci-dessus
BONUS - Dashboard	Streamlit ou Plotly Dash : courbe temps r�el + clusters du jour + pr�vision interactive	+2

TOTAL : 20 POINTS + 2 BONUS

Reproductibilit  (random_state=42 partout) : condition sine qua non.

Justification de chaque choix m thodologique : essentielle pour la notation.

Figures comment es (pas juste affich es) : chaque graphique doit avoir une conclusion.

14. Checklist Finale — Avant la Soutenance

Code & Notebook

- ☐ random_state=42 fix  dans tous les mod les
- ☐ Notebook ex cut  dans l'ordre (Kernel → Restart & Run All)
- ☐ Figures sauvegard es en PNG (dpi=150 minimum)
- ☐ requirements.txt   jour
- ☐ D p t GitHub final push  et lien/QR code dans le rapport

Rapport PDF

- ☐ Page de garde compl te (noms, ENSPD, ann e)
- ☐ Table des mati res num rot e avec num ros de pages
- ☐ Chaque figure a un titre ET un commentaire d'interpr tation
- ☐ Sections s ries temporelles incluses (obligatoire #07)
- ☐ Pr vision 7 jours avec IC 95% pr sente
- ☐ Rapport de risques de surcharge pr sent
- ☐ Bibliographie avec datasets ET librairies
- ☐ Imprim  recto-verso, reli 

PowerPoint

- ☐ Maximum 8 lignes de texte par slide
- ☐ Tous les membres du groupe ont des slides   pr senter
- ☐ R p tition chronom tr e faite (15 min pile)
- ☐ Captures d' cran du notebook incluses (pas de code live)
- ☐ R ponses aux 4 questions de d part clairement visibles

Questions types pr par es

- ☐ Pourquoi k=4 pour K-Means ?
- ☐ Qu'est-ce que SARIMA et pourquoi l'utiliser ?
- ☐ Que feriez-vous diff remment avec plus de donn es ?
- ☐ Pourquoi interpoler et non supprimer les valeurs manquantes ?
- ☐ Comment interpr ter les axes de l'ACP ?

Bon courage   toute l' quipe ! ⚡

ENSPD Douala — Cours AD2, 2025/2026 — Enseignant : M. FOTSO Valdez