

 COLE NATIONALE SUP RIEURE POLYTECHNIQUE DE DOUALA
D partement Informatique — Fili re SDIA

BIBLE DU PROJET AD2 — #07

Pr vision de la Consommation  lectrique au Cameroun

Guide de R f rence Complet · Pipeline EDA - ARIMA

Cours : Analyse de Donn es 2 (AD2)
Enseignant : M. FOTSO Valdez
Groupe de 5  tudiants · Ann e 2025/2026
ENSPD Douala

0. Vue d'ensemble du Projet

Ce document constitue la BIBLE officielle du Groupe #07. Il r capitule,  tape par  tape, tout ce que votre  quipe doit produire, comment le coder, comment le r diger et comment le pr senter. Gardez-le ouvert pendant toute la dur e du projet.

0.1 Fiche d'identit  du projet

Crit�re	D�tail
Num�ro du projet	#07
Domaine	�nergie & D�veloppement Durable
M�thode factorielle	ACP — Analyse en Composantes Principales (non supervis�)
ARIMA	OBLIGATOIRE (pas optionnel)
Difficult�	Avanc�
Groupe	5 �tudiants
Note totale	20 points + 2 bonus
Enseignant	M. FOTSO Valdez

0.2 Les 4 questions auxquelles vous devez r pondre

QUESTIONS CL S   TRAITER (bar me direct)

- Q1 — Quels sont les patterns horaires, journaliers et saisonniers de consommation ?
 Q2 — Comment la temp rature influence-t-elle la consommation ?
 Q3 — Peut-on pr voir la consommation des 48 prochaines heures (et des 7 jours) ?
 Q4 — Quelles p riodes pr sentent les risques de surcharge les plus  lev s ?

0.3 Pipeline global (EDA → ARIMA)

�tape	Nom	M�thode	Points
1	Exploration (EDA)	pandas, seaborn, matplotlib	4 pts (mutualis� avec pr�pro)
2	Pr�traitement	StandardScaler, interpolation, IQR	� idem
3	D�composition temporelle	seasonal_decompose, ADF	Obligatoire #07
4	ACP	PCA sklearn (95 % variance)	3 pts
5	Clustering K-Means	KMeans, coude, silhouette	4 pts (mutualis� DBSCAN)
6	Clustering DBSCAN	DBSCAN (eps, min_samples)	� idem
7	Classification	DecisionTree + RandomForest	4 pts
8	SARIMA	SARIMAX statsmodels	Inclus dans les crit�res ci-dessus
BONUS	Dashboard	Plotly Dash ou Streamlit	+2 pts

1. Organisation de l' quipe & R les

1.1 Tableau des r les

R�le	Pr�nom � remplir	Responsabilit�s principales	Sections rapport
Chef de projet		Planification, GitHub (branches/PR), r�unions quotidiennes 9h, communication enseignant, int�gration finale	Introduction, Conclusion
Resp. Code		Structure d�p�t, notebook final, random_state=42, revue de code, requirements.txt	Annexes code
Resp. Rapport		R�daction sections 2-6, qualit� figures, normes (police, pages, reliure)	EDA, Pr�traitement, ACP
Resp. Pr�sentation		Cr�ation slides PowerPoint, coordination oral, minutage, design	Clustering, Classification
Resp. Validation		Tests mod�les, m�triques, hypoth�ses (stationnarit�), gestion conflits Git	S�ries temporelles

1.2 Planning 10 jours

Jour	T�ches cl�s	Responsable(s)
J1	Installation Python 3.10, pandas, sklearn, statsmodels. Cr�ation GitHub, .gitignore, requirements.txt. R�cup�ration dataset.	Tous + Chef
J2	EDA compl�te : stats, visualisations, corr�lations, saisonnalit�. D�but r�daction section EDA.	Resp. Rapport + Code
J3	Pr�traitement : NA, variables temporelles, normalisation, outliers IQR.	Resp. Code + Validation
J4	ACP : scree plot, cercle corr�lations, interpr�tation axes. Int�gration rapport.	Resp. Code + Rapport
J5	Clustering : K-Means (coude, silhouette) + DBSCAN. Visualisation profils.	Resp. Code + Validation
J6	Classification : Arbre + Random Forest, validation crois�e, importance variables.	Resp. Code + Validation
J7	S�ries temporelles : ADF, ACF/PACF, SARIMA, pr�vision 7 jours, m�triques.	Resp. Code + Validation
J8	Finalisation notebook, v�rif random_state, r�daction conclusion/annexes.	Tous
J9	Cr�ation PowerPoint, r�p�tition soutenance chronom�tr�e.	Resp. Pr�sentation + Tous
J10	Impression rapport (recto-verso, reliure), envoi notebook, push GitHub final.	Chef + Tous

2. Donn es — Sources & Structure

2.1 Sources recommand es

Source	URL / Lien	Usage
Kaggle – Hourly Energy Consumption (PJM/AEP)	kaggle.com/datasets/robikscube/hourly-energy-consumption	Donn�es horaires MW — rebaptis�es « ENEO synth�tiques »
Open Power System Data	open-power-system-data.org	Profils de charge europ�ens (inspiration)
World Bank – Energy	data.worldbank.org/topic/energy-and-mining	Indicateurs macro Cameroun (PIB, pop)
IEA – Africa Energy Outlook	iea.org/reports/africa-energy-outlook-2022	Contexte africain, s�ries de r�f�rence

NOTE P DAGOGIQUE ACCEPT E PAR L'ENSEIGNANT

Faute de donn es publiques camerounaises d taill es, vous pouvez utiliser le jeu AEP (American Electric Power) et le rebaptiser « Donn es ENEO synth tiques ».

Justification   inclure dans le rapport : climatologie tropicale similaire (double pointe journali re) + urbanisation croissante = profil de charge comparable.

2.2 Variables du dataset

Variable	Type	Description	Source
datetime	Index DatetimeIndex	Horodatage horaire (pas = 1h)	Raw dataset
consumption	float (MW)	Consommation �lectrique en m�gawatts	Raw dataset
temperature	float (�C)	Temp�rature ext�rieure	M�t�o (� merger)
humidity	float (%)	Humidit� relative	M�t�o (� merger)
hour	int 0-23	Heure extraite du datetime	Feature engineering
day_of_week	int 0-6	Jour de la semaine (0=Lundi)	Feature engineering
month	int 1-12	Mois de l'ann�e	Feature engineering
is_weekend	int 0/1	1 si samedi ou dimanche	Feature engineering

2.3 G n ration synth tique (si aucune donn e disponible)

Si vous ne pouvez pas t l charger de dataset, cr ez une s rie r aliste avec numpy :

```
import numpy as np, pandas as pd
np.random.seed(42)
n = 8760 # 1 an horaire
t = np.arange(n)
```

```
tendance = 0.01 * t
saison_annuelle = 50 * np.sin(2*np.pi*t/8760) # saison s che/pluies
saison_jour = 100 * np.sin(2*np.pi*(t % 24)/24 - np.pi/2) # double pointe
bruit = np.random.normal(0, 20, n)
conso = 500 + tendance + saison_annuelle + saison_jour + bruit
idx = pd.date_range('2023-01-01', periods=n, freq='h')
df = pd.DataFrame({'consumption': conso}, index=idx)
```

→ Mentionnez explicitement dans le rapport que les donn es sont synth tiques et justifiez la mod lisation choisie.

3.  tape 1 — EDA (Exploratory Data Analysis)

BAR ME : 4 points (mutualis s avec pr traitement)

Visualisations pertinentes et comment es, gestion NA, cr ation variables temporelles, justifications.

3.1 Statistiques descriptives

Ce qu'on attend dans le rapport : tableaux min, max, moyenne, m diane,  cart-type, valeurs manquantes.

```
df.info()
df.describe()
df.isnull().sum()
```

3.2 Visualisations temporelles obligatoires

Visualisation	Code cl�	Interpr�tation attendue
Courbe sur 1 mois	df['2023-01'].plot(figsize=(14,4))	Tendance + double pointe visible
Courbe sur 1 semaine	df['2023-01-01':'2023-01-07'].plot()	Profil semaine/week-end distinct
Courbe sur 1 jour	df['2023-01-03'].plot()	Creux 2h-5h, pointe 7h + 20h
Boxplot par heure	df.groupby('hour')['consumption'].plot.box()	Heures de pointe et creuses
Heatmap corr�lations	sns.heatmap(df.corr(), annot=True)	Liens conso � temp�rature, heure
Courbe rolling mean	df.rolling(24*7).mean().plot()	Tendance liss�e sur 7 jours

3.3 Code EDA complet

```
import pandas as pd, matplotlib.pyplot as plt, seaborn as sns

# Feature engineering temporel
df['hour'] = df.index.hour
df['day_of_week'] = df.index.dayofweek
df['month'] = df.index.month
df['is_weekend'] = (df['day_of_week'] >= 5).astype(int)

# Boxplot par heure   heures de pointe
fig, ax = plt.subplots(figsize=(14, 5))
df.boxplot(column='consumption', by='hour', ax=ax)
ax.set_title('Distribution horaire de la consommation')
plt.suptitle('')
plt.tight_layout()
plt.savefig('eda_boxplot_horaire.png', dpi=150)

# Heatmap heure   jour
```

```
pivot = df.pivot_table(values='consumption', index='hour', columns='day_of_week',  
aggfunc='mean')  
sns.heatmap(pivot, cmap='YlOrRd', annot=True, fmt='.0f')  
plt.title('Consommation moyenne heure x jour de semaine')  
plt.savefig('eda_heatmap_jour.png', dpi=150)
```

4.  tape 2 — Pr traitement

4.1 Gestion des valeurs manquantes

R GLE #07 : interpolation lin aire (ne jamais supprimer des lignes dans une s rie temporelle).

```
df['consumption'] = df['consumption'].interpolate(method='linear')
# V rification
assert df['consumption'].isnull().sum() == 0, 'Valeurs manquantes restantes !'
```

4.2 D tection d'outliers (IQR)

Attention : conservez les pointes de consommation — ce sont des  v nements d'int r t m tier (pas des erreurs).

```
Q1 = df['consumption'].quantile(0.25)
Q3 = df['consumption'].quantile(0.75)
IQR = Q3 - Q1
lower, upper = Q1 - 3*IQR, Q3 + 3*IQR # seuil plus large que 1.5
outliers = df[(df['consumption'] < lower) | (df['consumption'] > upper)]
print(f'{len(outliers)} outliers d tect s (probables d lestages ou pics)')
```

4.3 Normalisation / Standardisation

Technique	Quand l'utiliser	Code
StandardScaler	ACP, clustering, classification	from sklearn.preprocessing import StandardScaler X_scaled = StandardScaler().fit_transform(X)
MinMaxScaler	Optionnel pour ARIMA	from sklearn.preprocessing import MinMaxScaler X_norm = MinMaxScaler().fit_transform(X)

4.4 Feature engineering complet

```
df['hour'] = df.index.hour
df['day_of_week'] = df.index.dayofweek
df['month'] = df.index.month
df['is_weekend'] = (df['day_of_week'] >= 5).astype(int)
df['quarter'] = df.index.quarter
# Lags (bonus)
df['lag_24h'] = df['consumption'].shift(24) # m me heure hier
df['lag_168h'] = df['consumption'].shift(168) # m me heure semaine pass e
df['roll_24h'] = df['consumption'].rolling(24).mean() # moyenne mobile 24h
```

5.  tape 3 — D composition & Stationnarit  (Obligatoire #07)

LIVRABLE SP CIFIQUE #07

D composition saisonni re multi- chelle (tendance + saisonnalit  journali re + annuelle).
Test de stationnarit  ADF avant mod lisation SARIMA.

5.1 D composition saisonni re

```
from statsmodels.tsa.seasonal import seasonal_decompose

# D composition sur donn es journali res (agr g es)
daily = df['consumption'].resample('D').mean()
decomp = seasonal_decompose(daily, model='additive', period=7)
fig = decomp.plot()
fig.set_size_inches(14, 10)
plt.suptitle('D composition saisonni re - Consommation ENEO (quotidien)', y=1.02)
plt.tight_layout()
plt.savefig('decomposition_saisonniere.png', dpi=150)

# D composition horaire (saisonnalit  journali re)
decomp_h = seasonal_decompose(df['consumption'], model='additive', period=24)
```

5.2 Test de stationnarit  ADF

La s rie doit  tre stationnaire avant d'ajuster ARIMA. $p\text{-value} < 0.05 \rightarrow$ stationnaire.

```
from statsmodels.tsa.stattools import adfuller

def test_adf(series, name='s rie'):
    result = adfuller(series.dropna())
    print(f'--- Test ADF : {name} ---')
    print(f' Statistique ADF : {result[0]:.4f}')
    print(f' p-value : {result[1]:.4f}')
    print(f' Stationnaire : {"OUI" if result[1] < 0.05 else "NON - diff rencier"}')
    return result[1] < 0.05

stationnaire = test_adf(daily, 'Consommation journali re')
if not stationnaire:
    daily_diff = daily.diff().dropna()
    test_adf(daily_diff, 'Consommation diff renci e (d=1)')
```

5.3 ACF / PACF — Identification des ordres p, d, q

```
from statsmodels.graphics.tsaplots import plot_acf, plot_pacf

fig, (ax1, ax2) = plt.subplots(2, 1, figsize=(14, 8))
plot_acf(daily_diff, lags=40, ax=ax1, title='ACF - Autocorr lation (  ordre q)')
plot_pacf(daily_diff, lags=40, ax=ax2, title='PACF - Autocorr lation partielle (  ordre p)')
plt.tight_layout()
plt.savefig('acf_pacf.png', dpi=150)
```

→ q = dernier lag significatif dans l'ACF. p = dernier lag significatif dans le PACF.

6.  tape 4 — ACP (Analyse en Composantes Principales)

BAR ME : 3 points

Scree plot, plan factoriel, cercle des corr lations, variance expliqu e, interpr tation des axes.

6.1 Matrice d'entr e pour l'ACP

L'ACP s'applique sur les variables m t o et temporelles (pas directement sur la s rie de consommation).

```
features_acp = ['temperature', 'humidity', 'hour', 'day_of_week', 'month',
                'is_weekend']
X = df[features_acp].dropna()
from sklearn.preprocessing import StandardScaler
X_scaled = StandardScaler().fit_transform(X)
```

6.2 Code ACP complet

```
from sklearn.decomposition import PCA
import numpy as np, matplotlib.pyplot as plt

# ACP avec 95% de variance expliqu e
pca = PCA(n_components=0.95, random_state=42)
components = pca.fit_transform(X_scaled)
print(f'Nombre de composantes retenues : {pca.n_components_}')
print(f'Variance expliqu e cumul e      : {pca.explained_variance_ratio_.cumsum()}')

# — Scree Plot —
plt.figure(figsize=(8, 5))
plt.bar(range(1, pca.n_components_+1), pca.explained_variance_ratio_*100,
        color='steelblue')
plt.plot(range(1, pca.n_components_+1),
         pca.explained_variance_ratio_.cumsum()*100, 'r-o')
plt.xlabel('Composante principale')
plt.ylabel('Variance expliqu e (%)')
plt.title('Scree Plot — ACP Consommation ENEO')
plt.axhline(y=95, color='green', linestyle='--', label='Seuil 95%')
plt.legend()
plt.savefig('acp_scree.png', dpi=150)

# — Cercle des corr lations (axes 1 et 2) —
fig, ax = plt.subplots(figsize=(7, 7))
circle = plt.Circle((0,0), 1, fill=False, color='gray', linestyle='--')
ax.add_patch(circle)
for i, feat in enumerate(features_acp):
    ax.annotate(feat, xy=(pca.components_[0][i], pca.components_[1][i]),
               fontsize=11)
    ax.arrow(0, 0, pca.components_[0][i], pca.components_[1][i],
            head_width=0.03, color='navy')
ax.set_xlim(-1.2, 1.2); ax.set_ylim(-1.2, 1.2)
ax.set_xlabel('PC1'); ax.set_ylabel('PC2')
ax.set_title('Cercle des corr lations — ACP')
plt.savefig('acp_cercle.png', dpi=150)
```

6.3 Interpr tation attendue dans le rapport

Axe	Interpr�tation probable	Variables dominantes
PC1	Opposition jour / nuit	hour (+), is_weekend (-)
PC2	Opposition saison s�che / pluies	month (+), humidity (-)
PC3	Effet thermique (si retenu)	temperature (+), humidity (-)

Note : remplacez les variables m t o par les 2–3 premi res composantes pour le clustering.

7.  tape 5 — Clustering (K-Means + DBSCAN)

BAR ME : 4 points

K-Means (m thode du coude + silhouette) ET DBSCAN, comparaison, profilage m tier des clusters.

7.1 K-Means — D termination du k optimal

```
from sklearn.cluster import KMeans
from sklearn.metrics import silhouette_score
import matplotlib.pyplot as plt

inertias, silhouettes = [], []
K_range = range(2, 9)
for k in K_range:
    km = KMeans(n_clusters=k, random_state=42, n_init=10)
    labels = km.fit_predict(X_scaled)
    inertias.append(km.inertia_)
    silhouettes.append(silhouette_score(X_scaled, labels))

fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(14, 5))
ax1.plot(K_range, inertias, 'bo-'); ax1.set_title('M thode du coude (inertie)')
ax2.plot(K_range, silhouettes, 'gs-'); ax2.set_title('Score silhouette')
plt.savefig('kmeans_choix_k.png', dpi=150)
```

7.2 K-Means — Profilage des clusters

```
k_optimal = 4 #   ajuster selon le coude/silhouette
km_final = KMeans(n_clusters=k_optimal, random_state=42, n_init=10)
df['cluster_kmeans'] = km_final.fit_predict(X_scaled)

# Courbe de consommation moyenne par cluster
fig, axes = plt.subplots(1, k_optimal, figsize=(16, 4))
for c in range(k_optimal):
    subset = df[df['cluster_kmeans'] == c]
    subset.groupby('hour')['consumption'].mean().plot(ax=axes[c])
    axes[c].set_title(f'Cluster {c} - n={len(subset)}')
plt.suptitle('Profil horaire de consommation par cluster')
plt.savefig('kmeans_profils.png', dpi=150)
```

7.3 DBSCAN — D tection des journ es atypiques

DBSCAN identifie les points aberrants sans forcer tous les points dans un cluster. Les labels=-1 sont les anomalies (d lestages, pointes extr mes).

```
from sklearn.cluster import DBSCAN

# Tester plusieurs eps
for eps_val in [0.3, 0.5, 0.8, 1.0]:
    db = DBSCAN(eps=eps_val, min_samples=5)
    labels_db = db.fit_predict(X_scaled)
    n_noise = (labels_db == -1).sum()
```

```
print(f'eps={eps_val} → {len(set(labels_db))-1} clusters, {n_noise} anomalies')

# Mod le final
db_final = DBSCAN(eps=0.5, min_samples=5)
df['cluster_dbscan'] = db_final.fit_predict(X_scaled)
anomalies = df[df['cluster_dbscan'] == -1]
print(f'Anomalies d tect es : {len(anomalies)} heures
({len(anomalies)/len(df)*100:.1f}%)')
```

7.4 Comparaison K-Means vs DBSCAN (  mettre dans le rapport)

Crit�re	K-Means	DBSCAN
Nombre de clusters	Fix� a priori (k=4)	D�couvert automatiquement
Gestion des outliers	Force tous les points dans un cluster	Isole les anomalies (label=-1)
Forme des clusters	Clusters sph�riques seulement	Formes arbitraires
Utilisation #07	Profilage des journ�es type	D�tection d�lestages/surcharges
Param�tre cl�	k (m�thode du coude)	eps + min_samples (grille de recherche)

8.  tape 6 — Classification Supervis e

BAR ME : 4 points

2 mod les (Arbre + Random Forest), validation crois e 5-fold, m triques F1/recall, importance des variables, interpr tation de la matrice de confusion.

8.1 D finition de la variable cible

Seuil recommand  : 90e percentile de la consommation = jour « critique » (  risque de surcharge).

```
seuil = df['consumption'].quantile(0.90)
df['critique'] = (df['consumption'] >= seuil).astype(int)
print(f'Seuil critique : {seuil:.1f} MW')
print(f'Distribution : {df["critique"].value_counts()})
```

8.2 Arbre de D cision

```
from sklearn.tree import DecisionTreeClassifier, export_text
from sklearn.model_selection import train_test_split, cross_val_score
from sklearn.metrics import classification_report, confusion_matrix

features = ['temperature', 'humidity', 'hour', 'day_of_week', 'month',
            'is_weekend']
X_cls = df[features].dropna()
y_cls = df.loc[X_cls.index, 'critique']

X_train, X_test, y_train, y_test = train_test_split(
    X_cls, y_cls, test_size=0.2, random_state=42, stratify=y_cls)

dt = DecisionTreeClassifier(max_depth=5, random_state=42)
dt.fit(X_train, y_train)
y_pred_dt = dt.predict(X_test)
print('=== ARBRE DE D CISION ===')
print(classification_report(y_test, y_pred_dt))
print(confusion_matrix(y_test, y_pred_dt))
```

8.3 Random Forest + importance des variables

```
from sklearn.ensemble import RandomForestClassifier
import pandas as pd, matplotlib.pyplot as plt

rf = RandomForestClassifier(n_estimators=200, random_state=42, n_jobs=-1)
rf.fit(X_train, y_train)
y_pred_rf = rf.predict(X_test)

# Validation crois e 5-fold
scores = cross_val_score(rf, X_cls, y_cls, cv=5, scoring='f1')
print(f'F1 moyen (CV 5-fold) : {scores.mean():.3f} ± {scores.std():.3f}')

# Importance des variables
importances = pd.Series(rf.feature_importances_,
                        index=features).sort_values(ascending=False)
```

```
importances.plot.bar(figsize=(10, 5), color='steelblue')
plt.title('Importance des variables - Random Forest')
plt.savefig('rf_importance.png', dpi=150)
```

8.4 Tableau comparatif   ins rer dans le rapport

M�trique	Arbre de D�cision	Random Forest	Meilleur mod�le
Accuracy	� mesurer	� mesurer	RF g�n�ralement
Pr�cision (critique)	� mesurer	� mesurer	RF
Rappel (critique)	� mesurer	� mesurer	RF
F1-score (critique)	� mesurer	� mesurer	RF
CV 5-fold F1	� mesurer	� mesurer	RF
Interpr�tabilit�	Haute (arbre visible)	Moyenne (bo�te noire)	Arbre

9.  tape 7 — S ries Temporelles SARIMA (OBLIGATOIRE)

LIVRABLES OBLIGATOIRES #07

- ✓ Pr vision 7 jours avec intervalles de confiance   95%
- ✓ D composition saisonni re multi- chelle
- ✓ Rapport de risques de surcharge

9.1 Agr gation en donn es journali res

```
daily = df['consumption'].resample('D').mean()
print(f'S rie journali re : {len(daily)} jours')

# Split train/test 80/20
n = len(daily)
split = int(n * 0.8)
train, test = daily[:split], daily[split:]
print(f'Train : {len(train)} jours | Test : {len(test)} jours')
```

9.2 Identification des ordres avec auto_arima (recommand )

```
# Installation : pip install pmdarima
from pmdarima import auto_arima

model_auto = auto_arima(train,
                        seasonal=True, m=7, # saisonnalit  hebdomadaire
                        d=None,             # auto-diff renciation
                        trace=True,         # affiche les mod les test s
                        error_action='ignore',
                        suppress_warnings=True)

print(model_auto.summary())
p, d, q = model_auto.order
P, D, Q, s = model_auto.seasonal_order
```

9.3 Ajustement SARIMA

```
from statsmodels.tsa.statespace.sarimax import SARIMAX
import warnings
warnings.filterwarnings('ignore')

# Param tres identifi s par auto_arima (exemple)
p, d, q = 1, 1, 1
P, D, Q, s = 1, 0, 1, 7

model = SARIMAX(train, order=(p, d, q),
                seasonal_order=(P, D, Q, s),
                enforce_stationarity=False,
                enforce_invertibility=False)

results = model.fit(dispatch=False)
print(results.summary())
```

9.4 Prév́ision 7 jours avec intervalles de confiance 95%

```
# Prév́ision sur la période test
pred_test = results.get_prediction(start=test.index[0], end=test.index[-1])
pred_ci = pred_test.conf_int(alpha=0.05) # 95%

# Prév́ision future 7 jours
forecast = results.get_forecast(steps=7)
pred_mean = forecast.predicted_mean
conf_int = forecast.conf_int(alpha=0.05)

# — Graphique complet —
fig, ax = plt.subplots(figsize=(16, 6))
train[-60:].plot(ax=ax, label='Train (60 derniers jours)', color='steelblue')
test.plot(ax=ax, label='Réal (test)', color='green')
pred_test.predicted_mean.plot(ax=ax, label='Prédit (test)', color='orange',
                             linestyle='--')
pred_mean.plot(ax=ax, label='Prév́ision 7 jours', color='red', linestyle='--')
ax.fill_between(conf_int.index,
                conf_int.iloc[:,0], conf_int.iloc[:,1],
                color='red', alpha=0.15, label='IC 95%')
ax.set_title('Prév́ision SARIMA - Consommation ENEO - 7 jours')
ax.set_ylabel('Consommation (MW)')
ax.legend(loc='upper left')
plt.tight_layout()
plt.savefig('sarima_prevision_7j.png', dpi=150)
```

9.5 Métriques d'évaluation

```
from sklearn.metrics import mean_absolute_error, mean_squared_error
import numpy as np

y_true = test.values
y_pred = pred_test.predicted_mean.values[:len(y_true)]

mae = mean_absolute_error(y_true, y_pred)
rmse = np.sqrt(mean_squared_error(y_true, y_pred))
mape = np.mean(np.abs((y_true - y_pred) / y_true)) * 100

print(f'MAE : {mae:.2f} MW')
print(f'RMSE : {rmse:.2f} MW')
print(f'MAPE : {mape:.2f} %')
```

9.6 Rapport de risques de surcharge

Définissez un seuil de surcharge (ex. 95e percentile de la consommation) et identifiez les périodes à risque dans la prév́ision.

```
seuil_surcharge = daily.quantile(0.95)
risques = pred_mean[pred_mean > seuil_surcharge]
print(f'Périodes à risque dans les 7 prochains jours :')
print(risques)
```

10. Livrables & Structure du Rapport

10.1 Tableau des livrables

Livrable	Format	Sp�cifications	Responsable
Rapport PDF	Imprim� reli�	20–40 pages recto-verso, reliure spirale/thermocoll, couverture imprim�e	Resp. Rapport + Tous
PowerPoint	Fichier .pptx	15–25 slides, 15 min pr�sentation + 5 min Q&A, tous les membres parlent	Resp. Pr�sentation + Tous
Notebook Jupyter	Fichier .ipynb	Un seul fichier, cellules ex�cut�es dans l'ordre, random_state=42, envoy� par email	Resp. Code + Tous
Code Python	GitHub priv�	Scripts structur�s, QR code dans le rapport, branches par r�le	Resp. Code

10.2 Structure obligatoire du rapport PDF

Section	Contenu attendu	Pages estim�es
Page de garde	Titre, noms, ENSPD, ann�e acad�mique, photo groupe optionnel	1
Table des mati�res	Num�rot�e avec num�ros de pages	1
1. Introduction	Contexte ENEO/SONATREL, probl�matique, objectifs, plan du rapport	2–3
2. EDA	Dataset (origine, taille, p�riode), stats descriptives, visualisations comment�es	4–6
3. Pr�traitement	Gestion NA (interpolation), features engineering, normalisation — chaque choix justifi�	2–3
4. ACP	Scree plot comment�, cercle des corr�lations interpr�t�, variance expliqu�e, axes nomm�s	2–3
5. Clustering	K-Means (coude, silhouette, k choisi), DBSCAN (eps, min_samples), comparaison tableau	3–4
6. Classification	2 mod�les, m�triques, matrice de confusion, importance variables, comparatif	3–4
7. S�ries temporelles	D�composition, ADF, ACF/PACF, SARIMA ajust�, pr�vision 7j + IC, m�triques, surcharges	4–6
8. Conclusion	R�ponses aux 4 questions, limites, recommandations ENEO	2
Bibliographie	Datasets, librairies Python, articles de r�f�rence	1
Annexes	Code Python complet OU QR code GitHub, tableaux compl�mentaires	3–5

10.3 Livrables sp cifiques #07 (notation directe)

LIVRABLES UNIQUES AU PROJET #07 — OBLIGATOIRES

- ✓ Graphique de décomposition saisonnière multi-échelle (journalier + annuel) commenté
- ✓ Prévion de consommation sur 7 jours avec intervalles de confiance 95%
- ✓ Rapport sur les périodes de risque de surcharge avec recommandations ENEO
(ex : renforcer la production entre 18h-22h en saison sèche, prévoir délestage tournant...)

11. Guide Git & Workflow de Collaboration

11.1 Structure du d p t

```
projet07_consommation/  
├─ README.md  
├─ requirements.txt  
├─ .gitignore  
├─ notebooks/  
│   └─ projet07_final.ipynb  
├─ scripts/  
│   ├── eda.py  
│   ├── preprocessing.py  
│   ├── acp.py  
│   ├── clustering.py  
│   ├── classification.py  
│   └─ sarima.py  
├─ data/  
│   └─ (ne jamais committer les donn es brutes)  
├─ figures/  
└─ rapport/
```

11.2 Branches par membre

Membre	Branche	R�pertoire principal
Chef de projet	feature/integration	rapport/, slides/, README.md
Resp. Code	feature/notebook	notebooks/, scripts/
Resp. Rapport	feature/rapport	rapport/ (Word ou LaTeX)
Resp. Pr�sentation	feature/presentation	presentation/
Resp. Validation	feature/validation	tests/, validation/

11.3 Workflow quotidien

```
# Chaque matin (9h00 – point de 10 min)  
git checkout main  
git pull origin main  
git checkout feature/ma-branche  
git merge main # r cup rer les derni res modifs  
  
# Travailler, puis committer  
git add .  
git commit -m "feat: ajout d composition saisonni re journali re"  
git push -u origin feature/ma-branche  
  
# Cr er une Pull Request sur GitHub (vers main)  
# → Revue par le Chef de projet → Merge
```

11.4 .gitignore essentiel

```
# Environnements
venv/
__pycache__/
.ipynb_checkpoints/

# Donn es (jamais committer)
data/*.csv
data/*.xlsx

# OS
.DS_Store
Thumbs.db
```

11.5 requirements.txt

```
pandas>=2.0.0
numpy>=1.24.0
matplotlib>=3.7.0
seaborn>=0.12.0
scikit-learn>=1.3.0
statsmodels>=0.14.0
pmdarima>=2.0.0
jupyter>=1.0.0
plotly>=5.0.0
streamlit>=1.28.0 # si bonus dashboard
```

12. Guide de Soutenance Orale

12.1 R partition des r les   l'oral (15 min)

Membre	Partie	Dur�e	Slides
Membre 1 (Chef)	Introduction + Contexte ENEO	2 min	Slides 1–3
Membre 2 (Rapport)	EDA + Pr�traitement	3 min	Slides 4–8
Membre 3 (Code)	ACP + Clustering	3 min	Slides 9–13
Membre 4 (Pr�sentation)	Classification	3 min	Slides 14–18
Membre 5 (Validation)	SARIMA + Pr�vision + Conclusion	4 min	Slides 19–25

12.2 Structure des slides PowerPoint

Slide	Contenu
1	TITRE : Projet #07 — Pr�vision Consommation ENEO + Noms + ENSPD
2	CONTEXTE : Probl�me des d�lestages, ENEO/SONATREL, les 4 questions cl�s
3	DATASET : Source, taille, p�riode, variables principales
4-5	EDA : Courbes multi-�chelle + boxplot horaire + heatmap heure�jour
6	PR�TRAITEMENT : Choix justifi�s (interpolation NA, features cr��es)
7-8	ACP : Scree plot + cercle des corr�lations comment�
9-11	CLUSTERING : M�thode du coude + profils K-Means + anomalies DBSCAN
12-14	CLASSIFICATION : 2 mod�les, tableau m�triques, importance variables
15-17	SARIMA : D�composition + ACF/PACF + pr�vision 7 jours avec IC 95%
18	RISQUES DE SURCHARGE : P�riodes critiques identifi�es
19-20	CONCLUSION : R�ponses aux 4 questions + Recommandations ENEO

12.3 Questions types   pr parer

QUESTIONS FR QUENTES DU PROFESSEUR — PR PAREZ VOS R PONSES

Q: Pourquoi avoir choisi $k=4$ pour K-Means ?

  Parce que la m thode du coude montre un coude marqu    $k=4$ et que le score silhouette est maximal pour cette valeur. Cela correspond aux 4 profils : journ e critique, mod r e, basse, et week-end.

Q: Qu'est-ce qu'un mod le SARIMA et pourquoi l'utiliser ici ?

  SARIMA = AutoRegressive Integrated Moving Average Saisonnier. Il capte la tendance, l'autocorr lation et la saisonnalit  p riodique de la s rie. Id al pour la consommation  lectrique qui a une double saisonnalit  (journali re + hebdomadaire).

Q: Que feriez-vous diff remment avec plus de donn es ?

→ Prophet (Meta) ou LSTM pour mieux capturer plusieurs saisons. Plus de variables exog nes

(donn es m t o locales Douala, jours f ri s camerounais, PIB r gional).

Q: Pourquoi interpoler et non supprimer les valeurs manquantes ?

→ Dans une s rie temporelle, supprimer des lignes cr e des trous qui faussent la saisonnalit . L'interpolation lin aire est coh rente avec la continuit  temporelle.

13. Bar me d' valuation D taill 

Crit�re	Sous-crit�res not�s	Points
EDA + Pr�traitement	Visualisations pertinentes (multi-�chelle), stats descriptives, gestion NA (interpolation), creation variables temporelles, d�tection outliers IQR justifi�e	4
ACP	Scree plot avec seuil 95%, cercle des corr�lations lisible et comment�, nombre de composantes justifi�, axes nomm�s (jour/nuit, saison s�che/pluies)	3
Clustering	K-Means : coude + silhouette + profilage m�tier des clusters. DBSCAN : eps/min_samples choisis + anomalies interpr�t�es. Comparaison des deux m�thodes.	4
Classification	2 mod�les (Arbre + RF), validation crois�e 5-fold, F1/recall/pr�cision, matrice de confusion comment�e, importance des variables Random Forest	4
Rapport + Pr�sentation	Structure obligatoire respect�e, figures comment�es, pas de blocs de code bruts, qualit� r�dactionnelle, tous les membres parlent, slides < 8 lignes	3
ARIMA (obligatoire)	D�composition multi-�chelle, ADF + diff�renciation si n�cessaire, ACF/PACF, SARIMA ajust�, pr�vision 7j + IC95%, MAE/RMSE/MAPE, rapport surcharges	Inclus ci-dessus
BONUS — Dashboard	Streamlit ou Plotly Dash : courbe temps r�el + clusters du jour + pr�vision interactive	+2

TOTAL : 20 POINTS + 2 BONUS

Reproductibilit  (random_state=42 partout) : condition sine qua non.

Justification de chaque choix m thodologique : essentielle pour la notation.

Figures comment es (pas juste affich es) : chaque graphique doit avoir une conclusion.

14. Checklist Finale — Avant la Soutenance

Code & Notebook

- ☐ random_state=42 fix  dans tous les mod les
- ☐ Notebook ex cut  dans l'ordre (Kernel → Restart & Run All)
- ☐ Figures sauvegard es en PNG (dpi=150 minimum)
- ☐ requirements.txt   jour
- ☐ D p t GitHub final push  et lien/QR code dans le rapport

Rapport PDF

- ☐ Page de garde compl te (noms, ENSPD, ann e)
- ☐ Table des mati res num rot e avec num ros de pages
- ☐ Chaque figure a un titre ET un commentaire d'interpr tation
- ☐ Sections s ries temporelles incluses (obligatoire #07)
- ☐ Pr vision 7 jours avec IC 95% pr sente
- ☐ Rapport de risques de surcharge pr sent
- ☐ Bibliographie avec datasets ET librairies
- ☐ Imprim  recto-verso, reli 

PowerPoint

- ☐ Maximum 8 lignes de texte par slide
- ☐ Tous les membres du groupe ont des slides   pr senter
- ☐ R p tition chronom tr e faite (15 min pile)
- ☐ Captures d' cran du notebook incluses (pas de code live)
- ☐ R ponses aux 4 questions de d part clairement visibles

Questions types pr par es

- ☐ Pourquoi k=4 pour K-Means ?
- ☐ Qu'est-ce que SARIMA et pourquoi l'utiliser ?
- ☐ Que feriez-vous diff remment avec plus de donn es ?
- ☐ Pourquoi interpoler et non supprimer les valeurs manquantes ?
- ☐ Comment interpr ter les axes de l'ACP ?

Bon courage   toute l' quipe ! ⚡

ENSPD Douala — Cours AD2, 2025/2026 — Enseignant : M. FOTSO Valdez